

## PROGRAMACIÓN CONCURRENTE - Trabajo Práctico 2 Parte 3 (GPU)

### INTEGRANTES DEL EQUIPO:

Fierro Agustin 42427695  
Galindo Ricardo 33786709  
Uranga Esteban 39389794  
Cocciardi Agustin 40231779  
Battistelli Agustin 41129795

### Enunciado:

Se debe poner capturas de pantallas de las distintas ejecuciones. Los ejercicios se encuentran en el siguiente enlace

[https://github.com/Progc-unlam/material-progc/blob/main/Ejemplos/GPU/TP\\_2\\_Parte\\_3\\_GPU.ipynb](https://github.com/Progc-unlam/material-progc/blob/main/Ejemplos/GPU/TP_2_Parte_3_GPU.ipynb)

### Introducción:

### Preguntas del TP:

- a) A continuación se especifican los bloques de código donde se llevan a cabo las siguientes partes:

#### Reservar memoria en GPU:

```
img_O_gpu = cuda.mem_alloc( img_O_cpu.nbytes )  
img_R_gpu = cuda.mem_alloc( img_R_cpu.nbytes )
```

#### Transferir datos de la CPU a la GPU:

```
cuda.memcpy_htod( img_O_gpu, img_O_cpu )  
cuda.memcpy_htod( img_R_gpu, img_R_cpu )
```

#### Transferir el kernel y ejecutar el algoritmo:

```

module = SourceModule("""
#define PIXEL_ROJO( x,y) (x+(y*ancho))*3
#define PIXEL_VERDE(x,y) PIXEL_ROJO(x,y) + 1
#define PIXEL_AZUL( x,y) PIXEL_ROJO(x,y) + 2

__global__ void kernel_img( int ancho, int alto, int *img_O, int *img_R )
{
    // Calculo las coordenadas del Thread en dos dimensiones.
    int idx = threadIdx.x + blockIdx.x*blockDim.x;
    int idy = threadIdx.y + blockIdx.y*blockDim.y;
    float fGris = 0.0;

    // Verifico que los Thread, esten dentro de las dimensiones de la imagen.
    if( idx < ancho && idy < alto )
    {
        // Calculo el color gris para el pixel a partir de los componentes.
        fGris = (float)img_O[ PIXEL_ROJO( idx, idy ) ]*0.29; // Componente Rojo del pixel.
        fGris +=(float)img_O[ PIXEL_VERDE( idx, idy ) ]*0.59; // Componente Verde del pixel.
        fGris +=(float)img_O[ PIXEL_AZUL( idx, idy ) ]*0.11; // Componente Azul del pixel.
        // Escribo el color del pixel.
        img_R[ PIXEL_ROJO( idx, idy ) ] = (int) fGris;
        img_R[ PIXEL_VERDE( idx, idy ) ] = (int) fGris;
        img_R[ PIXEL_AZUL( idx, idy ) ] = (int) fGris;
    }
}
""")

# -----
kernel = module.get_function("kernel_img")

dim_hilo_x = 6
dim_bloque_x = int( (img_ancho+dim_hilo_x-1) / dim_hilo_x )

dim_hilo_y = 6
dim_bloque_y = int( (img_alto+dim_hilo_y-1) / dim_hilo_y )

# -----
kernel( numpy.int32(img_ancho), numpy.int32(img_alto), img_O_gpu, img_R_gpu,
        block=( dim_hilo_x, dim_hilo_y, 1 ),
        grid=(dim_bloque_x, dim_bloque_y,1) )

```

Transferir datos de la GPU a la CPU:

```

"""
cuda.memcpy_dtoh( img_R_cpu, img_R_gpu )

```

Limpiar memoria:

```

img_O_gpu.free()
img_R_gpu.free()

```

- b) ¿Cuál es la configuración inicial(por defecto) de Grilla y Bloques con que se ejecuta el algoritmo?

Los bloques utilizan dimensiones de [6,6] (definida en el propio código) mientras que la grilla utiliza dimensiones de [171, 128] (depende de las dimensiones de alto y ancho de la imagen a utilizar).

- c) ¿Cuántos hilos se crean en total cuando se llama al kernel? **Tips:** utilice la formula  $dim\_hilo\_x * dim\_bloque\_x * dim\_hilo\_y * dim\_bloque\_y$  para calcular la cantidad de threads total

Utilizando la fórmula provista para calcular el número de hilos y sabiendo que los valores son:

`dim_hilo_x = 6`

`dim_bloque_x = 171`

`dim_hilo_y = 6`

`dim_bloque_y = 128`

Se obtiene que se utilizarán en total unos **787968** threads.

- d) ¿Cuántos hilos se planifican de más? **Tips:** Los que no tengan condición verdadera en la condición dentro del kernel.

Dado a que cada pixel de la imagen utiliza un thread dentro de GPU, se puede calcular el número total de threads multiplicando las dimensiones de alto y ancho de la imagen. Las dimensiones en este caso son 1024 y 768, por lo que el número de threads total que serían necesarios son **786432**.

Dado a que voy a crear 787968 threads en total, si le resto los 786432 que voy a usar, obtengo un total de **1536** threads que se van a crear de más.

- e) Modifique el código del Kernel, para que en lugar de aplicar escalas de grises a la imagen, aplique el filtro de inversión de colores.

Código del algoritmo para inversión de colores:

```
__global__ void kernel_img( int ancho, int alto, int *img_O, int *img_R )
{
    // Calculo las coordenadas del Thread en dos dimensiones.
    int idx = threadIdx.x + blockIdx.x*blockDim.x;
    int idy = threadIdx.y + blockIdx.y*blockDim.y;
    int pixelRojo, pixelAzul, pixelVerde = 0;

    // Verifico que los Thread, esten dentro de las dimensiones de la imagen.
    if( idx < ancho && idy < alto )
    {
        // Calculo el color gris para el pixel a partir de los componentes.
        pixelRojo = 255-img_O[ PIXEL_ROJO( idx, idy ) ]; // Componente Rojo del pixel.
        pixelVerde = 255-img_O[ PIXEL_VERDE( idx, idy ) ]; // Componente Verde del pixel.
        pixelAzul = 255-img_O[ PIXEL_AZUL( idx, idy ) ]; // Componente Azul del pixel.
        // Escribo el color del pixel.
        img_R[ PIXEL_ROJO( idx, idy ) ] = pixelRojo;
        img_R[ PIXEL_VERDE( idx, idy ) ] = pixelVerde;
        img_R[ PIXEL_AZUL( idx, idy ) ] = pixelAzul;
    }
}
```

Resultado:



- f) Utilice NVProf para medir la velocidad de respuesta que tiene el algoritmo durante su ejecución de acuerdo a la siguiente configuración y describa qué sucede con los tiempos.

El máximo tamaño de un bloque que soporta GPU se obtuvo con el comando previsto en el Colab.

(16,19,1):

```

==2702== NVPROF is profiling process 2702, command: python3 filter_image.py
Imagen del filtro: imagen.jpg - tipo RGB - [ 1024 , 768 ]
Imagen del filtro: imagen.jpg - tipo RGB - [ 1024 , 768 ]
Grilla : [ 171 , 128 ], Bloques: [ 16 , 19 ]
==2702== Profiling application: python3 filter_image.py
==2702== Profiling result:

```

Type	Time(%)	Time	Calls	Avg	Min	Max	Name
GPU activities:	66.14%	7.3202ms	1	7.3202ms	7.3202ms	7.3202ms	[CUDA memcopy DtoH]
	32.11%	3.5534ms	2	1.7767ms	1.7741ms	1.7792ms	[CUDA memcopy HtoD]
	1.75%	193.47us	1	193.47us	193.47us	193.47us	kernel_img
API calls:	83.27%	228.26ms	1	228.26ms	228.26ms	228.26ms	cuCtxCreate
	11.43%	31.337ms	1	31.337ms	31.337ms	31.337ms	cuCtxDetach
	3.44%	9.4221ms	1	9.4221ms	9.4221ms	9.4221ms	cuMemcpyDtoH
	1.47%	4.0283ms	2	2.0141ms	1.9302ms	2.0981ms	cuMemcpyHtoD
	0.22%	601.66us	2	300.83us	134.40us	467.26us	cuMemFree
	0.09%	259.73us	2	129.87us	92.007us	167.73us	cuMemAlloc
	0.03%	87.116us	1	87.116us	87.116us	87.116us	cuModuleLoadDataEx
	0.02%	44.795us	1	44.795us	44.795us	44.795us	cuModuleUnload
	0.01%	39.724us	1	39.724us	39.724us	39.724us	cuLaunchKernel
	0.00%	7.3020us	1	7.3020us	7.3020us	7.3020us	cuDeviceGetPCIBusId
	0.00%	4.2420us	2	2.1210us	605ns	3.6370us	cuCtxPopCurrent
	0.00%	3.3920us	2	1.6960us	244ns	3.1480us	cuCtxPushCurrent
	0.00%	2.8150us	3	938ns	677ns	1.2300us	cuDeviceGetAttribute
	0.00%	2.7050us	3	901ns	299ns	1.5250us	cuDeviceGetCount
	0.00%	1.8160us	1	1.8160us	1.8160us	1.8160us	cuModuleGetFunction
	0.00%	1.7850us	2	892ns	746ns	1.0390us	cuCtxGetDevice
	0.00%	1.2190us	2	609ns	488ns	731ns	cuDeviceGet
	0.00%	1.1110us	1	1.1110us	1.1110us	1.1110us	cuDeviceComputeCapability
	0.00%	731ns	1	731ns	731ns	731ns	cuFuncSetBlockShape

(24,24,1):

```

==2986== NVPROF is profiling process 2986, command: python3 filter_image.py
Imagen del filtro: imagen.jpg - tipo RGB - [ 1024 , 768 ]
Imagen del filtro: imagen.jpg - tipo RGB - [ 1024 , 768 ]
Grilla : [ 171 , 128 ], Bloques: [ 24 , 24 ]
==2986== Profiling application: python3 filter_image.py
==2986== Profiling result:

```

Type	Time(%)	Time	Calls	Avg	Min	Max	Name
GPU activities:	60.89%	6.5637ms	1	6.5637ms	6.5637ms	6.5637ms	[CUDA memcopy DtoH]
	34.26%	3.6927ms	2	1.8464ms	1.8398ms	1.8530ms	[CUDA memcopy HtoD]
	4.85%	522.91us	1	522.91us	522.91us	522.91us	kernel_img
API calls:	83.52%	216.68ms	1	216.68ms	216.68ms	216.68ms	cuCtxCreate
	10.95%	28.412ms	1	28.412ms	28.412ms	28.412ms	cuCtxDetach
	3.44%	8.9202ms	1	8.9202ms	8.9202ms	8.9202ms	cuMemcpyDtoH
	1.63%	4.2185ms	2	2.1093ms	2.0489ms	2.1696ms	cuMemcpyHtoD
	0.24%	618.44us	2	309.22us	140.78us	477.66us	cuMemFree
	0.15%	377.80us	2	188.90us	158.20us	219.60us	cuMemAlloc
	0.05%	121.11us	1	121.11us	121.11us	121.11us	cuModuleLoadDataEx
	0.02%	43.223us	1	43.223us	43.223us	43.223us	cuModuleUnload
	0.01%	25.725us	1	25.725us	25.725us	25.725us	cuLaunchKernel
	0.00%	7.6660us	2	3.8330us	899ns	6.7670us	cuCtxGetDevice
	0.00%	6.2930us	1	6.2930us	6.2930us	6.2930us	cuDeviceGetPCIBusId
	0.00%	4.1230us	2	2.0610us	377ns	3.7460us	cuCtxPopCurrent
	0.00%	3.6290us	2	1.8140us	180ns	3.4490us	cuCtxPushCurrent
	0.00%	3.0520us	3	1.0170us	267ns	1.5360us	cuDeviceGetCount
	0.00%	2.7470us	3	915ns	723ns	1.1440us	cuDeviceGetAttribute
	0.00%	1.3140us	2	657ns	436ns	878ns	cuDeviceGet
	0.00%	1.2760us	1	1.2760us	1.2760us	1.2760us	cuModuleGetFunction
	0.00%	884ns	1	884ns	884ns	884ns	cuDeviceComputeCapability
	0.00%	867ns	1	867ns	867ns	867ns	cuFuncSetBlockShape

Máximo soportado por GPU (1024, 1024, 64):

```

==3396== NVPROF is profiling process 3396, command: python3 filter_image.py
Traceback (most recent call last):
  File "/content/filter_image.py", line 69, in <module>
    kernel( numpy.int32(img_ancha), numpy.int32(img_alto), img_0_gpu, img_R_gpu,
  File "/usr/local/lib/python3.10/dist-packages/pycuda/driver.py", line 481, in function_call
    func._set_block_shape(*block)
pycuda.driver.LogicError: cuFuncSetBlockShape failed: invalid argument
==3396== Profiling application: python3 filter_image.py
==3396== Profiling result:
   Type  Time(%)    Time       Calls      Avg       Min       Max  Name
GPU activities: 100.00%  3.5973ms         2  1.7986ms  1.7906ms  1.8067ms  [CUDA memcpy HtoD]
  API calls:   86.46%  223.55ms         1  223.55ms  223.55ms  223.55ms  cuCtxCreate
              11.52%  29.794ms         1  29.794ms  29.794ms  29.794ms  cuCtxDetach
              1.57%  4.0683ms         2  2.0341ms  1.9558ms  2.1125ms  cuMemcpyHtoD
              0.26%  663.15us         2  331.58us  199.04us  464.11us  cuMemFree
              0.12%  312.24us         2  156.12us  99.734us  212.51us  cuMemAlloc
              0.04%  114.05us         1  114.05us  114.05us  114.05us  cuModuleLoadDataEx
              0.01%  21.968us         1  21.968us  21.968us  21.968us  cuModuleUnload
              0.00%  7.7150us         2  3.8570us      856ns  6.8590us  cuCtxGetDevice
              0.00%  6.7070us         1  6.7070us  6.7070us  6.7070us  cuDeviceGetPCIBusId
              0.00%  3.4380us         3  1.1460us      276ns  1.6500us  cuDeviceGetCount
              0.00%  3.1510us         4      787ns      210ns  2.2940us  cuCtxPopCurrent
              0.00%  2.8130us         4      703ns      158ns  1.9320us  cuCtxPushCurrent
              0.00%  2.7740us         3      924ns      638ns  1.2760us  cuDeviceGetAttribute
              0.00%  1.8670us         1  1.8670us  1.8670us  1.8670us  cuModuleGetFunction
              0.00%  1.3270us         2      663ns      624ns      703ns  cuDeviceGet
              0.00%  1.0230us         1  1.0230us  1.0230us  1.0230us  cuDeviceComputeCapability
              0.00%      872ns         1      872ns      872ns      872ns  cuFuncSetBlockShape
              0.00%      770ns         1      770ns      770ns      770ns  cuGetErrorString

===== Error: Application returned non-zero code 1

```

Al usar una dimensión de bloque mucho mayor que la que se había definido inicialmente, el tiempo de ejecución del kernel no se ve reducido, esto porque ya se había visto que al utilizar una dimensión de bloque de (6,6) el número de hilos creados terminó siendo superior al número que iban a utilizarse. Incrementar la dimensión de bloque no hará que los hilos creados trabajen más rápido, solamente tendré más hilos ociosos en tiempo de ejecución.

g) En el punto anterior ¿Qué sucedió al medir el tiempo con máximo de Threads soportados por la GPU?

Se produjo un error debido a que la forma de bloque no es válida para la función de kernel, siendo que se está trabajando en dos dimensiones (X e Y), y para obtener el máximo de threads que soporta la GPU es necesario disponer de la dimensión Z. Pero revisando lo ocurrido al aumentar el número de hilos en X e Y, y viendo que eso no produce aceleraciones en el tiempo, asumimos que utilizando la máxima cantidad de hilos, su tiempo sería superior al tiempo de ejecución con dimensiones (24,24,1).

h) Mida el tiempo de respuesta que tiene el algoritmo con la dimension "X" en su maxima capacidad y el resto en 1 (ej:(1024,1,1)). Luego modifique la configuración para que la dimension "Y" tenga su maxima capacidad y el resto en 1.(ej:(1,1024,1)) Compare los resultado. ¿A que cree que se debe la diferencia de tiempo?

(1024,1,1):

```

==6418== NVPROF is profiling process 6418, command: python3 filter_image.py
Imagen del filtro: imagen.jpg - tipo RGB - [ 1024 , 768 ]
Imagen del filtro: imagen.jpg - tipo RGB - [ 1024 , 768 ]
Grilla : [ 171 , 128 ], Bloques: [ 1024 , 1 ]
==6418== Profiling application: python3 filter_image.py
==6418== Profiling result:

```

Type	Time(%)	Time	Calls	Avg	Min	Max	Name
GPU activities:	66.31%	9.3126ms	1	9.3126ms	9.3126ms	9.3126ms	[CUDA memcpy DtoH]
	29.74%	4.1765ms	2	2.0882ms	1.9308ms	2.2456ms	[CUDA memcpy HtoD]
	3.95%	555.04us	1	555.04us	555.04us	555.04us	kernel_img
API calls:	83.18%	278.10ms	1	278.10ms	278.10ms	278.10ms	cuCtxCreate
	11.33%	37.880ms	1	37.880ms	37.880ms	37.880ms	cuCtxDetach
	3.65%	12.209ms	1	12.209ms	12.209ms	12.209ms	cuMemcpyDtoH
	1.42%	4.7587ms	2	2.3794ms	2.1382ms	2.6206ms	cuMemcpyHtoD
	0.21%	712.00us	2	356.00us	205.38us	506.62us	cuMemFree
	0.13%	431.79us	2	215.89us	155.40us	276.39us	cuMemAlloc
	0.04%	136.67us	1	136.67us	136.67us	136.67us	cuModuleLoadDataEx
	0.02%	52.782us	1	52.782us	52.782us	52.782us	cuModuleUnload
	0.01%	35.048us	1	35.048us	35.048us	35.048us	cuLaunchKernel
	0.00%	9.0220us	1	9.0220us	9.0220us	9.0220us	cuDeviceGetPCIBusId
	0.00%	5.7550us	1	5.7550us	5.7550us	5.7550us	cuModuleGetFunction
	0.00%	4.4960us	2	2.2480us	772ns	3.7240us	cuCtxPopCurrent
	0.00%	4.2280us	2	2.1140us	354ns	3.8740us	cuCtxPushCurrent
	0.00%	3.3750us	3	1.1250us	362ns	1.6580us	cuDeviceGetCount
	0.00%	2.1070us	2	1.0530us	938ns	1.1690us	cuCtxGetDevice
	0.00%	1.6470us	3	549ns	275ns	1.0380us	cuDeviceGetAttribute
	0.00%	1.3100us	1	1.3100us	1.3100us	1.3100us	cuDeviceComputeCapability
	0.00%	1.2870us	2	643ns	643ns	644ns	cuDeviceGet
	0.00%	981ns	1	981ns	981ns	981ns	cuFuncSetBlockShape

(1,1024,1):

```

==6706== NVPROF is profiling process 6706, command: python3 filter_image.py
Imagen del filtro: imagen.jpg - tipo RGB - [ 1024 , 768 ]
Imagen del filtro: imagen.jpg - tipo RGB - [ 1024 , 768 ]
Grilla : [ 171 , 128 ], Bloques: [ 1 , 1024 ]
==6706== Profiling application: python3 filter_image.py
==6706== Profiling result:

```

Type	Time(%)	Time	Calls	Avg	Min	Max	Name
GPU activities:	63.60%	7.6545ms	1	7.6545ms	7.6545ms	7.6545ms	[CUDA memcpy DtoH]
	31.03%	3.7345ms	2	1.8673ms	1.7965ms	1.9380ms	[CUDA memcpy HtoD]
	5.37%	645.82us	1	645.82us	645.82us	645.82us	kernel_img
API calls:	83.83%	233.05ms	1	233.05ms	233.05ms	233.05ms	cuCtxCreate
	10.55%	29.339ms	1	29.339ms	29.339ms	29.339ms	cuCtxDetach
	3.69%	10.248ms	1	10.248ms	10.248ms	10.248ms	cuMemcpyDtoH
	1.49%	4.1548ms	2	2.0774ms	1.9469ms	2.2079ms	cuMemcpyHtoD
	0.23%	642.68us	2	321.34us	177.40us	465.28us	cuMemFree
	0.11%	308.48us	2	154.24us	101.46us	207.02us	cuMemAlloc
	0.05%	142.11us	1	142.11us	142.11us	142.11us	cuModuleLoadDataEx
	0.02%	45.796us	1	45.796us	45.796us	45.796us	cuModuleUnload
	0.01%	31.752us	1	31.752us	31.752us	31.752us	cuLaunchKernel
	0.00%	6.9160us	1	6.9160us	6.9160us	6.9160us	cuModuleGetFunction
	0.00%	6.8420us	1	6.8420us	6.8420us	6.8420us	cuDeviceGetPCIBusId
	0.00%	4.7510us	2	2.3750us	497ns	4.2540us	cuCtxPopCurrent
	0.00%	3.9030us	3	1.3010us	376ns	2.0950us	cuDeviceGetCount
	0.00%	3.5730us	2	1.7860us	231ns	3.3420us	cuCtxPushCurrent
	0.00%	2.8750us	3	958ns	691ns	1.1790us	cuDeviceGetAttribute
	0.00%	1.6950us	2	847ns	806ns	889ns	cuCtxGetDevice
	0.00%	1.2210us	2	610ns	529ns	692ns	cuDeviceGet
	0.00%	1.0040us	1	1.0040us	1.0040us	1.0040us	cuFuncSetBlockShape
	0.00%	951ns	1	951ns	951ns	951ns	cuDeviceComputeCapability

La diferencia de tiempo se debe a la agrupación de los threads en unidades de ejecución. Si se elige una dimensión de (1024,1,1) el máximo número de threads se agrupan dentro de una sola unidad. En cambio, si se elige la dimensión de (1,1024,1) se tendrán un total de 1024 unidades de ejecución utilizando únicamente un hilo cada una. Lo que hará al algoritmo menos eficiente que si se utilizaran los máximos hilos en la dimensión de X.

- i) ¿Qué cambios realizaría para que solo se procese la parte derecha de la imagen?  
 ¿Qué sucede con la parte izquierda en la imagen resultante? ¿Qué sucede con la velocidad de respuesta?

Los cambios que realizaría para procesar solo la parte derecha de la imagen serían los siguientes:



```

if( idx < ancho && idy < alto )
{
    // Calculo el color gris para el pixel a partir de los componentes.
    if (idx > (ancho/2))
    {
        pixelRojo = 255-img_O[ PIXEL_ROJO( idx, idy ) ]; // Componente Rojo del pixel.
        pixelVerde = 255-img_O[ PIXEL_VERDE( idx, idy ) ]; // Componente Verde del pixel.
        pixelAzul = 255-img_O[ PIXEL_AZUL( idx, idy ) ]; // Componente Azul del pixel.
        // Escribo el color del pixel.
        img_R[ PIXEL_ROJO( idx, idy ) ] = pixelRojo;
        img_R[ PIXEL_VERDE( idx, idy ) ] = pixelVerde;
        img_R[ PIXEL_AZUL( idx, idy ) ] = pixelAzul;
    }
    else
    {
        pixelRojo = img_O[ PIXEL_ROJO( idx, idy ) ]; // Componente Rojo del pixel.
        pixelVerde = img_O[ PIXEL_VERDE( idx, idy ) ]; // Componente Verde del pixel.
        pixelAzul = img_O[ PIXEL_AZUL( idx, idy ) ]; // Componente Azul del pixel.
        // Escribo el color del pixel.
        img_R[ PIXEL_ROJO( idx, idy ) ] = pixelRojo;
        img_R[ PIXEL_VERDE( idx, idy ) ] = pixelVerde;
        img_R[ PIXEL_AZUL( idx, idy ) ] = pixelAzul;
    }
}
}

```


Para procesar los píxeles de la parte derecha, tengo que preguntar si el índice de x es mayor a la mitad del ancho de la imagen. Aunque también tengo que colocar un else para setear los píxeles de la mitad izquierda de la imagen iguales a su color original, de lo contrario, la parte izquierda me quedará de negro al no tener como asignarle el color a los píxeles.

Resultado cuando aplico el filtro a la parte derecha y no hago nada con la parte izquierda:





Resultado cuando aplico el filtro a la parte derecha y proceso la parte izquierda para dejarla igual a la original:



Tiempo de respuesta cuando aplico el filtro a toda la imagen:

```

==9130== NVPROF is profiling process 9130, command: python3 filter_image.py
Imagen del filtro: imagen.jpg - tipo RGB - [ 1024 , 768 ]
Imagen del filtro: imagen.jpg - tipo RGB - [ 1024 , 768 ]
Grilla : [ 171 , 128 ], Bloques: [ 6 , 6 ]
==9130== Profiling application: python3 filter_image.py
==9130== Profiling result:

```

Type	Time(%)	Time	Calls	Avg	Min	Max	Name
GPU activities:	61.97%	6.7206ms	1	6.7206ms	6.7206ms	6.7206ms	[CUDA memcpy DtoH]
	36.76%	3.9864ms	2	1.9932ms	1.9492ms	2.0373ms	[CUDA memcpy HtoD]
	1.27%	137.41us	1	137.41us	137.41us	137.41us	kernel_img
API calls:	83.59%	219.60ms	1	219.60ms	219.60ms	219.60ms	cuCtxCreate
	10.95%	28.767ms	1	28.767ms	28.767ms	28.767ms	cuCtxDetach
	3.31%	8.6842ms	1	8.6842ms	8.6842ms	8.6842ms	cuMemcpyDtoH
	1.72%	4.5088ms	2	2.2544ms	2.2300ms	2.2788ms	cuMemcpyHtoD
	0.23%	614.48us	2	307.24us	142.36us	472.12us	cuMemFree
	0.13%	345.27us	2	172.63us	155.27us	190.00us	cuMemAlloc
	0.04%	93.324us	1	93.324us	93.324us	93.324us	cuModuleLoadDataEx
	0.02%	43.036us	1	43.036us	43.036us	43.036us	cuModuleUnload
	0.01%	28.552us	1	28.552us	28.552us	28.552us	cuLaunchKernel
	0.00%	6.2040us	1	6.2040us	6.2040us	6.2040us	cuDeviceGetPCIBusId
	0.00%	4.6890us	1	4.6890us	4.6890us	4.6890us	cuModuleGetFunction
	0.00%	3.6760us	2	1.8380us	420ns	3.2560us	cuCtxPopCurrent
	0.00%	3.3510us	2	1.6750us	196ns	3.1550us	cuCtxPushCurrent
	0.00%	2.8540us	2	1.4270us	559ns	2.2950us	cuDeviceGet
	0.00%	2.6890us	3	896ns	668ns	1.2210us	cuDeviceGetAttribute
	0.00%	2.2280us	2	1.1140us	1.0110us	1.2170us	cuCtxGetDevice
	0.00%	2.2240us	3	741ns	292ns	1.0070us	cuDeviceGetCount
	0.00%	904ns	1	904ns	904ns	904ns	cuFuncSetBlockShape
	0.00%	875ns	1	875ns	875ns	875ns	cuDeviceComputeCapability

Tiempo de respuesta cuando aplico el filtro solo a la parte derecha (y me aseguro que la parte izquierda no quede de color negro):

```

==11788== NVPROF is profiling process 11788, command: python3 filter_image.py
Imagen del filtro: imagen.jpg - tipo RGB - [ 1024 , 768 ]
Imagen del filtro: imagen.jpg - tipo RGB - [ 1024 , 768 ]
Grilla : [ 171 , 128 ], Bloques: [ 6 , 6 ]
==11788== Profiling application: python3 filter_image.py
==11788== Profiling result:

```

Type	Time(%)	Time	Calls	Avg	Min	Max	Name
GPU activities:	66.27%	7.1412ms	1	7.1412ms	7.1412ms	7.1412ms	[CUDA memcpy DtoH]
	32.46%	3.4981ms	2	1.7491ms	1.7396ms	1.7585ms	[CUDA memcpy HtoD]
	1.27%	137.18us	1	137.18us	137.18us	137.18us	kernel_img
API calls:	82.11%	202.36ms	1	202.36ms	202.36ms	202.36ms	cuCtxCreate
	12.10%	29.812ms	1	29.812ms	29.812ms	29.812ms	cuCtxDetach
	3.70%	9.1230ms	1	9.1230ms	9.1230ms	9.1230ms	cuMemcpyDtoH
	1.62%	3.9951ms	2	1.9975ms	1.9383ms	2.0567ms	cuMemcpyHtoD
	0.26%	637.65us	2	318.83us	149.60us	488.06us	cuMemFree
	0.11%	282.20us	2	141.10us	95.19us	187.01us	cuMemAlloc
	0.05%	122.08us	1	122.08us	122.08us	122.08us	cuModuleLoadDataEx
	0.02%	56.883us	1	56.883us	56.883us	56.883us	cuModuleUnload
	0.01%	33.808us	1	33.808us	33.808us	33.808us	cuLaunchKernel
	0.00%	7.8020us	2	3.9010us	699ns	7.1030us	cuCtxGetDevice
	0.00%	7.0580us	1	7.0580us	7.0580us	7.0580us	cuDeviceGetPCIBusId
	0.00%	5.4130us	2	2.7060us	447ns	4.9660us	cuCtxPopCurrent
	0.00%	4.7430us	2	2.3710us	199ns	4.5440us	cuCtxPushCurrent
	0.00%	2.5950us	3	865ns	681ns	1.2070us	cuDeviceGetAttribute
	0.00%	2.4160us	3	805ns	231ns	1.1160us	cuDeviceGetCount
	0.00%	1.9340us	1	1.9340us	1.9340us	1.9340us	cuModuleGetFunction
	0.00%	1.3650us	2	682ns	545ns	820ns	cuDeviceGet
	0.00%	1.1130us	1	1.1130us	1.1130us	1.1130us	cuFuncSetBlockShape
	0.00%	939ns	1	939ns	939ns	939ns	cuDeviceComputeCapability

Tiempo de respuesta cuando aplico el filtro solo a la parte derecha (y dejo la parte izquierda sin procesar):

```

==12030== NVPROF is profiling process 12030, command: python3 filter_image.py
Imagen del filtro: imagen.jpg - tipo RGB - [ 1024 , 768 ]
Imagen del filtro: imagen.jpg - tipo RGB - [ 1024 , 768 ]
Grilla : [ 171 , 128 ], Bloques: [ 6 , 6 ]
==12030== Profiling application: python3 filter_image.py
==12030== Profiling result:

```

Type	Time(%)	Time	Calls	Avg	Min	Max	Name
GPU activities:	64.38%	7.0414ms	1	7.0414ms	7.0414ms	7.0414ms	[CUDA memcpy DtoH]
	34.95%	3.8226ms	2	1.9113ms	1.8109ms	2.0118ms	[CUDA memcpy HtoD]
	0.68%	74.016us	1	74.016us	74.016us	74.016us	kernel_img
API calls:	81.91%	203.20ms	1	203.20ms	203.20ms	203.20ms	cuCtxCreate
	12.27%	30.439ms	1	30.439ms	30.439ms	30.439ms	cuCtxDetach
	3.57%	8.8602ms	1	8.8602ms	8.8602ms	8.8602ms	cuMemcpyDtoH
	1.73%	4.2980ms	2	2.1490ms	1.9661ms	2.3319ms	cuMemcpyHtoD
	0.27%	681.05us	2	340.52us	195.91us	485.14us	cuMemFree
	0.13%	322.91us	2	161.46us	99.621us	223.29us	cuMemAlloc
	0.06%	159.93us	1	159.93us	159.93us	159.93us	cuModuleLoadDataEx
	0.02%	41.566us	1	41.566us	41.566us	41.566us	cuModuleUnload
	0.01%	30.953us	1	30.953us	30.953us	30.953us	cuLaunchKernel
	0.00%	7.0670us	1	7.0670us	7.0670us	7.0670us	cuDeviceGetPCIBusId
	0.00%	5.3800us	1	5.3800us	5.3800us	5.3800us	cuModuleGetFunction
	0.00%	4.5320us	2	2.2660us	518ns	4.0140us	cuCtxPopCurrent
	0.00%	3.3240us	2	1.6620us	192ns	3.1320us	cuCtxPushCurrent
	0.00%	2.5750us	3	858ns	269ns	1.1610us	cuDeviceGetCount
	0.00%	1.9690us	3	656ns	484ns	988ns	cuDeviceGetAttribute
	0.00%	1.5360us	2	768ns	743ns	793ns	cuCtxGetDevice
	0.00%	1.2730us	2	636ns	497ns	776ns	cuDeviceGet
	0.00%	938ns	1	938ns	938ns	938ns	cuDeviceComputeCapability
	0.00%	694ns	1	694ns	694ns	694ns	cuFuncSetBlockShape

Cada uno de los threads trabaja con un píxel de la imagen. Si quiero trabajar solo con una mitad del ancho de la imagen, la mitad de los threads no van a realizar ninguna tarea, por lo cual el tiempo se reduce casi por la mitad al usar el algoritmo.

**Link a repositorio de Github:**

## Conclusiones:

Una dificultad que afrontamos fue el seteo del entorno de ejecución. Ya que no teníamos seteado el acelerador por hardware como GPU, y al momento de ejecutar el desarrollo no se reconocía el módulo driver de la biblioteca pycuda y nos arrojaba error.

Además, otra de las dificultades que surgió en la realización de este tp fue implementar el algoritmo que se encarga de la inversión de los colores de la imagen. No por la complejidad del mismo, sino porque pensábamos que consistía en ir guardando los valores de los píxeles rojo, verde y azul en una variable de forma acumulativa, cuando lo que debíamos hacer era usar un valor entero para la conversión de los colores de cada pixel para la imagen.

## **Bibliografía:**